Ibmec-DF

Camila Sabino Ribeiro

Titulo Provisorio do TCC

Trabalho de Conclusao de Curso apresentado ao curso de Ciencias Economicas.

Brasilia
31 de outubro de 2026

Sumário

1 Introdução **1**

1.1 Contexto 1

1.2 Pergunta de pesquisa 2

1.3 Objetivos 3

1.3.1 Objetivo Geral 3

1.3.2 Objetivos Específicos 3

1.4 Justificativa 3

1.5 Estrutura do trabalho 4

2 Revisão de Literatura **5**

2.1 Base teórica - Paradigma Model-Based 5

2.1.1 Modelos de heterocedasticidade condicional: GARCH e EGARCH . 5

2.2 Base teórica - Paradigma Data-Driven 7

2.2.1 Random Forest 7

2.3 Evidência empírica 8

2.3.1 Aplicações ao mercado cambial brasileiro 8

2.3.2 Comparações entre paradigmas model-based e data-driven 9

3 Metodologia **10**

3.1 Desenho da pesquisa 10

3.2 Especificação dos modelos 12

3.2.1 Modelos de heterocedasticidade condicional: GARCH e EGARCH . 12

3.2.2 Modelo data-driven: Random Forest 13

3.3 Estratégia de avaliação fora da amostra 13

3.4 Limitações 15

4 Base de Dados e Estrategia Empirica **16**

4.1 Fontes de dados 16

4.2 Construcao das variaveis 16

4.3 Tratamento dos dados 17

5 Resultados **18**
5.1 Análise descritiva 18
5.2 Resultados principais 20
5.3 Testes de robustez 23

6 Conclusão **27**
6.1 Sintese dos resultados 27
6.2 Contribuições 27
6.3 Agenda futura 28

A Resultados complementares **29**
A.1 Gráficos complementares 29
A.2 Resultados dos testes estatísticos 31

B Resultados complementares dos modelos **32**
B.1 Estimação dos modelos GARCH 32
B.2 Estimação dos modelos EGARCH 32
B.3 Importância das variáveis do Random Forest 33
B.4 Resultados completos do teste Diebold-Mariano 33
B.5 Diagnóstico da estimação do modelo EGARCH na janela rolante 34
B.6 Importância das variáveis do Random Forest com janela rolante 34
B.7 Resultados completos do teste Diebold-Mariano com janela rolante 35

Capítulo 1

Introdução

1.1 Contexto

A volatilidade dos preços de ativos financeiros é uma das variáveis mais relevantes em finanças quantitativas. Ela representa a dispersão dos retornos de um ativo ao longo do tempo e serve como insumo central para uma ampla quantidade de aplicações práticas, como o cálculo do Value at Risk (VaR) e do Expected Shortfall (ES), medidas utilizadas por bancos e gestoras de recursos para dimensionamento de reservas de capital, depende diretamente de estimativas precisas da volatilidade. Da mesma forma, a precificação de opções e demais derivativos financeiros, fundamentada no modelo pioneiro de Black e Scholes (1973), e as estratégias de alocação de portfólio baseadas em controle de risco (volatility targeting) são diretamente sensíveis à qualidade dessas estimativas. No âmbito regulatório, as reformas de Basileia III, especialmente as relacionadas à revisão da estrutura de risco de mercado, reforçaram a utilização do Expected Shortfall como medida de risco, evidenciando a importância de estimativas adequadas da volatilidade (BIS, 2019).

Entretanto, séries de retornos financeiros apresentam características que dificultam a modelagem estatística convencional, incluindo heterocedasticidade condicional, clustering de volatilidade, distribuições com caudas pesadas e evidências de assimetria na resposta da volatilidade a choques de mercado (Fama, 1965; Akgiray, 1989). Essas propriedades motivaram o desenvolvimento de duas abordagens distintas para a previsão de volatilidade. A primeira, denominada model-based, fundamenta-se em estruturas paramétricas previamente especificadas que impõem ao processo gerador de dados uma forma funcional interpretável. A segunda, denominada data-driven, opera sem pressupostos distribicionais rígidos e aprende os padrões diretamente da amostra. A comparação entre esses dois paradigmas constitui o objeto central deste trabalho.

No paradigma model-based, a família de modelos GARCH (Generalized Autoregressive Conditional Heteroskedasticity), introduzida por Engle (1982) e generalizada por Bollerslev (1986), se consolidou como referência acadêmica e prática ao capturar a persistência e

o agrupamento da volatilidade por meio de uma equação paramétrica para a variância condicional. Além disso, extensões como o EGARCH (Nelson, 1991) incorporam o efeito alavancagem, em que choques negativos tendem a elevar a volatilidade de forma assimétrica em relação a choques positivos de mesma magnitude. Em comum, esses modelos oferecem estruturas paramétricas interpretáveis para descrever a dinâmica da volatilidade. Entretanto, dependem de formas funcionais previamente especificadas, o que pode limitar sua capacidade de representar relações não lineares mais complexas e mudanças estruturais nos mercados financeiros.

Em contraposição, o avanço dos algoritmos de machine learning nas últimas décadas, em particular os métodos de ensemble baseados em árvores de decisão, como Random Forest, abriu a possibilidade de abordagens orientadas a dados com maior flexibilidade para identificar padrões não lineares. Esses modelos não impõem estrutura funcional ao processo gerador de dados, ajustando-se diretamente às relações empíricas observadas na amostra de treinamento. A questão central que emerge não é simplesmente qual modelo é superior, mas sob quais condições cada paradigma apresenta vantagem preditiva, e quais são os ganhos e perdas associados à troca de interpretabilidade por flexibilidade.

Nesse contexto, a taxa de câmbio USD/BRL constitui um objeto de análise particularmente relevante. O real brasileiro opera sob regime de câmbio flutuante desde 1999 e está sujeito a uma combinação de fatores externos, como variações na política monetária americana e ciclos de aversão ao risco global, e fatores idiossincráticos domésticos, incluindo incerteza fiscal e instabilidade política (Banco Central do Brasil, 2021). Como resultado, a volatilidade cambial brasileira é um fenômeno de natureza heterogênea e recorrentemente não linear, com episódios de elevada instabilidade que testam os limites de modelos paramétricos tradicionais. Adicionalmente, ao contrário do mercado acionário, não existe na literatura um modelo estrutural consagrado para explicar a volatilidade cambial, o que torna a comparação entre paradigmas de previsão especialmente pertinente e empiricamente aberta (Banco Central do Brasil, 2021; Campani e Durães, 2018).

1.2 Pergunta de pesquisa

Abordagens data-driven (Random Forest) apresentam desempenho preditivo superior às abordagens model-based (GARCH/EGARCH) na previsão da volatilidade diária da taxa de câmbio USD/BRL?

1.3 Objetivos

1.3.1 Objetivo Geral

O objetivo deste estudo é comparar o desempenho preditivo de abordagens model-based (GARCH/EGARCH) e data-driven (Random Forest) na previsão da volatilidade diária da taxa de câmbio USD/BRL, avaliando em que condições cada paradigma apresenta maior acurácia fora da amostra.

1.3.2 Objetivos Específicos

Para alcançar o objetivo geral, definem-se os seguintes passos:

- Estimar modelos GARCH(1,1) e EGARCH(1,1) sobre a série de retornos do USD/BRL e obter previsões de volatilidade fora da amostra;
- Treinar e calibrar modelo data-driven (Random Forest) com engenharia de features baseada em retornos defasados, proxies de volatilidade e indicadores de mercado;
- Comparar o desempenho preditivo dos modelos por meio de métricas de erro (MSE e QLIKE) e do teste Diebold-Mariano;

1.4 Justificativa

A rigidez paramétrica dos modelos tradicionais de volatilidade constitui um desafio relevante na modelagem de séries financeiras, especialmente em contextos caracterizados por elevada instabilidade. No caso da taxa de câmbio USD/BRL, essa limitação se torna particularmente significativa: a dinâmica cambial brasileira é influenciada simultaneamente por fundamentos macroeconômicos, fluxos de capital internacional e componentes de incerteza política doméstica, fatores que interagem de forma não linear e cujos efeitos sobre a volatilidade variam ao longo do tempo.

Evidências empíricas reforçam essa caracterização. O Banco Central do Brasil (2021) documenta que a volatilidade do câmbio BRL-USD responde a uma combinação de fatores externos e idiossincráticos domésticos, destacando a ausência de um modelo estrutural consagrado para sua explicação. No plano internacional, Chung, Espinoza e Quispe (2025) demonstram que, em períodos de crises agudas, a rigidez dos modelos GARCH pode resultar em redução significativa da capacidade preditiva. Paralelamente, Donaldson e Kamstra (1997) apresentaram evidências de que abordagens não lineares são capazes de capturar efeitos que escapam às equações tradicionais, potencial posteriormente reforçado por Kristjanpoller e Minutolo (2015) em testes com mercados de commodities.

Apesar desses avanços, ainda não há consenso na literatura sobre a superioridade das abordagens data-driven para previsão de volatilidade cambial em mercados emergentes,

onde características estruturais e institucionais específicas podem afetar o desempenho relativo dos modelos. Campani e Durães (2018), em estudo sobre o próprio mercado de câmbio USD/BRL, mostram que modelos GARCH estendidos com variáveis exógenas apresentam capacidade preditiva superior aos modelos univariados, sugerindo que a informação contida na estrutura do mercado cambial brasileiro é relevante, mas não necessariamente capturada da mesma forma por abordagens paramétricas e não paramétricas.

Desta forma, este trabalho contribui para a literatura ao comparar o desempenho preditivo de modelos model-based e data-driven na previsão da volatilidade diária da taxa de câmbio USD/BRL, com foco na acurácia fora da amostra, na avaliação estatística por meio do teste Diebold-Mariano, buscando avaliar se a flexibilidade do aprendizado de máquina se traduz em ganhos preditivos estatisticamente significativos em relação aos modelos econométricos tradicionais.

1.5 Estrutura do trabalho

Este trabalho está estruturado em seis capítulos, incluindo esta introdução. No segundo capítulo, apresenta-se a revisão de literatura, que abrange a base teórica e as evidências empíricas pertinentes ao tema, fundamentando a evolução dos modelos model-based de volatilidade e as aplicações de machine learning no setor financeiro, com ênfase no mercado cambial. O terceiro capítulo detalha a metodologia, descrevendo a hierarquia de modelos proposta, os critérios de avaliação e as limitações do estudo Em seguida, o quarto capítulo aborda a base de dados e a estratégia empírica, explicitando as fontes, a construção das variáveis e o tratamento de dados. Os resultados são discutidos no quinto capítulo, que compreende a análise descritiva, os resultados principais e testes de robustez, incluindo procedimentos de backtesting para validar a capacidade preditiva e a estabilidade do modelo proposto. Por fim, o sexto capítulo apresenta a conclusão, sintetizando os achados, as contribuições do trabalho e as sugestões para pesquisas futuras.

Capítulo 2

Revisão de Literatura

Este capítulo apresenta a base teórica e as evidências empíricas que fundamentam a estratégia metodológica adotada neste trabalho. A revisão está organizada em três partes. A primeira parte, composta pelas seções 2.1.1, percorre o paradigma model-based, apresentando os modelos de heterocedasticidade condicional (GARCH e EGARCH). A segunda parte, composta pela seção 2.2.1, apresenta o paradigma data-driven, descrevendo os fundamentos teóricos do algoritmo Random Forest. A terceira parte, na seção 2.3, reúne as evidências empíricas relevantes, com foco nas aplicações ao mercado cambial brasileiro e nas comparações diretas entre os dois paradigmas.

2.1 Base teórica - Paradigma Model-Based

O desenvolvimento teórico da modelagem financeira se fundamentou, inicialmente, na busca por leis estatísticas que pudessem descrever o comportamento dos ativos. Este paradigma, conhecido como model-based, se baseia em pressupostos teóricos sobre a eficiência dos mercados e a distribuição dos retornos. Fama (1965) consolidou um dos marcos fundamentais da hipótese de eficiência de mercado, sugerindo que os preços refletem todas as informações disponíveis e seguem um "passeio aleatório", o que implicaria na imprevisibilidade sistemática dos retornos futuros e independente do passado. Sob essa premissa de estabilidade, Black e Scholes (1973) desenvolveram seu modelo clássico de precificação de opções, que embora revolucionário, tratava a volatilidade como um parâmetro constante, uma limitação que a realidade dos mercados logo contestaria.

2.1.1 Modelos de heterocedasticidade condicional: GARCH e EGARCH

A percepção de que a incerteza é dinâmica levou ao surgimento dos modelos de heterocedasticidade condicional. O modelo ARCH, proposto por Engle (1982), permitiu que a variância condicional fosse modelada em função de choques passados, reconhecendo que períodos de

incerteza tendem a ser persistentes. Bollerslev (1986) refinou essa mecânica ao introduzir o componente autorregressivo no GARCH, possibilitando que a volatilidade dependesse não apenas de choques, mas de seu próprio histórico, conferindo maior parcimônia ao modelo.

A especificação geral de um processo GARCH(p,q) modela a variância condicional não apenas em função de q inovações quadradas passadas (termos ARCH), mas também de p variâncias condicionais defasadas (termos GARCH). A formulação matemática geral é dada por:

$$\sigma_t^2 = \omega + \sum_{i=1}^{q} \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^{p} \beta_j \sigma_{t-j}^2 \tag{2.1}$$

onde se impõe que $\omega > 0$, $\alpha_i \geq 0$ e $\beta_j \geq 0$ para garantir que a variância gerada seja estritamente positiva. Adicionalmente, se exige que a soma $\sum \alpha_i + \sum \beta_j < 1$ para assegurar a estacionariedade da covariância do processo. O estudo empírico clássico de Akgiray (1989) comprovou que as previsões da família GARCH superam notavelmente os métodos tradicionais (como Média Histórica e EWMA) ao modelarem com precisão o *clustering* (agrupamento) da volatilidade.

Um avanço teórico crítico para esta comparação é o reconhecimento das assimetrias. Nelson (1991), ao propor o EGARCH, introduziu a função de valor logarítmico para garantir a positividade da variância e, fundamentalmente, permitir que o modelo reagisse de forma distinta a retornos negativos e positivos. A generalização do modelo EGARCH(p,q), conforme detalhado na representação de Nelson (1991), utiliza a especificação da variância condicional no formato logarítmico, o que dispensa as restrições rígidas de positividade aos parâmetros e permite modelar respostas assimétricas:

$$\ln(\sigma_t^2) = \omega + \sum_{i=1}^{q} \left(\alpha_i \left| \frac{\varepsilon_{t-i}}{\sigma_{t-i}} \right| + \gamma_i \frac{\varepsilon_{t-i}}{\sigma_{t-i}} \right) + \sum_{j=1}^{p} \beta_j \ln(\sigma_{t-j}^2) \tag{2.2}$$

em que o termo direcional $\frac{\varepsilon_{t-i}}{\sigma_{t-i}}$ (frequentemente tratado como o resíduo padronizado) juntamente com o coeficiente γ_i, capturam diretamente a magnitude e a assimetria do choque no mercado.

Desse modo, os modelos GARCH e EGARCH representam uma abordagem paramétrica para a modelagem da dinâmica da volatilidade, permitindo descrever sua evolução por meio de estruturas matemáticas previamente especificadas e de parâmetros interpretáveis. Apesar de sua ampla utilização na modelagem da volatilidade e de sua capacidade de representar características típicas das séries financeiras, esses modelos dependem de uma estrutura funcional definida a priori. Essa característica pode limitar sua capacidade de capturar relações não lineares mais complexas e mudanças estruturais nos mercados financeiros. Nesse contexto, abordagens baseadas em aprendizado de máquina (Machine Learning), que permitem identificar padrões diretamente a partir dos dados, surgem como uma alternativa a ser investigada, sendo apresentadas na seção seguinte.

2.2 Base teórica - Paradigma Data-Driven

Como visto anteriormente, embora os modelos da família GARCH sejam a principal referência na modelagem paramétrica de volatilidade, eles impõem pressupostos distribucionais estritos e dependem da premissa de que os parâmetros são estáveis. Tais restrições frequentemente falham ao tentar capturar dinâmicas não lineares complexas e quebras estruturais repentinas no mercado financeiro. Para superar essa rigidez, a literatura recente passou a adotar algoritmos flexíveis de Machine Learning, que aprendem as relações não lineares diretamente dos dados (abordagem data-driven)

2.2.1 Random Forest

O *Random Forest*, apresentado por Breiman (2001), é um dos métodos de aprendizado em conjunto (*ensemble*) mais utilizados na literatura. Essa técnica constrói várias árvores de decisão, em que o crescimento de cada uma depende de um sorteio aleatório de dados, mantendo a mesma regra de distribuição para toda a floresta. Para garantir que as árvores sejam diferentes entre si (descorrelacionadas), o modelo usa a amostragem com reposição (*bagging*) junto com a escolha aleatória de variáveis em cada divisão da árvore.

Na teoria, Breiman (2001) usa a Lei dos Grandes Números para mostrar que o algoritmo é muito resistente ao *overfitting* (sobreajuste). Conforme a quantidade de árvores aumenta, o erro de generalização do modelo se estabiliza, impedindo que ele apenas "decore"os dados de treino. Em problemas de regressão (como é o caso de prever a volatilidade contínua), o autor explica que o desempenho da floresta depende de dois fatores principais: o erro médio das árvores individuais ($PE^*(\text{tree})$) e a correlação ponderada entre os seus resíduos ($\bar{\rho}$). Essa regra é dada pela seguinte desigualdade:

$$PE^*(\text{forest}) \leq \bar{\rho} PE^*(\text{tree}) \tag{2.3}$$

Isso significa que o sucesso do *Random Forest* exige um bom equilíbrio: produzir árvores que errem pouco individualmente, mas que sejam as mais independentes possíveis umas das outras.

Aplicando essa lógica ao mercado financeiro, Amoanu (2025) explica como o *Random Forest* é operacionalizado para prever séries temporais. Diferente dos modelos ARIMA e GARCH, que exigem regras matemáticas rígidas sobre a distribuição dos erros, o *Random Forest* funciona de forma mais livre (não paramétrica). Ele trata a previsão como um problema de aprendizado supervisionado, usando os valores passados da série (as defasagens, ou *lags*) como variáveis explicativas (*inputs*).

A previsão final do modelo para variáveis contínuas é simplesmente a média dos resultados fornecidos por cada árvore:

$$\hat{f}_{\mathrm{RF}}(x) = \frac{1}{B}\sum_{b=1}^{B} T_b(x) \tag{2.4}$$

em que B é o número total de árvores e $T_b(x)$ é a previsão da b-ésima árvore. Como Amoanu (2025) destaca, uma árvore sozinha tem pouco viés (erro sistemático), mas varia muito com qualquer mudança na amostra (alta variância). O *Random Forest* resolve exatamente esse problema ao tirar a média de várias árvores descorrelacionadas, ele derruba a variância da estimativa sem aumentar o viés. É por isso que o modelo se torna tão competitivo para capturar a complexidade e as não linearidades das séries financeiras.

2.3 Evidência empírica

2.3.1 Aplicações ao mercado cambial brasileiro

Prever a volatilidade no mercado de câmbio brasileiro é um desafio bastante complexo. Segundo o Banco Central do Brasil (2021), diferente do que ocorre com a taxa de câmbio em si, não existe um modelo estrutural definitivo para explicar as suas variações. Por isso, a prática comum é recorrer aos modelos econométricos da família GARCH. O problema, como alerta a própria instituição, é que nesses modelos o histórico da série (os termos autorregressivos) acaba absorvendo a maior parte da variação explicada no ajuste matemático, o que reduz o espaço para incluir outras variáveis importantes que também afetam o mercado.

Ao investigar a explosão na volatilidade do par BRL/USD após o choque da pandemia em 2020, o Banco Central do Brasil (2021) mostrou que o câmbio reage a uma mistura de turbulências internacionais (como o índice VIX e a instabilidade de outros países emergentes) e questões locais. O estudo apontou, por exemplo, que a entrada forte de pessoas físicas fazendo operações de curtíssimo prazo no mercado de minicontratos de dólar futuro teve um peso considerável no aumento da volatilidade durante aquele período.

Além da dinâmica de negociação do próprio mercado, o câmbio no Brasil é muito sensível à política. Moreira (2022) avaliou esse efeito utilizando o índice de incerteza política do país (EPUBR). Por meio de estimações econométricas (2SLS e GMM), o autor comprovou que o aumento da incerteza política gera uma elevação real e estatisticamente válida na volatilidade do dólar. Ele também confirmou que riscos geopolíticos e incertezas globais pioram esse cenário, deixando claro que a trajetória do câmbio sofre quebras frequentes causadas por fatores externos.

Falando especificamente de projeções matemáticas, Campani e Durães (2018) testaram a eficácia de modelos tradicionais na previsão da volatilidade do USD/BRL. Eles constataram que métodos clássicos, como o Desvio Padrão Histórico, o EWMA e o GARCH(1,1) simples, têm um desempenho muito parecido e limitado quando olham apenas para os retornos

diários de fechamento. No entanto, quando os autores estenderam o modelo EGARCH com informações extras do mercado (a volatilidade intradiária de alta frequência e a volatilidade implícita do índice FXVol da B3), a capacidade de acerto superou os métodos tradicionais de forma significativa.

Juntando os resultados de Campani e Durães (2018) com as análises do Banco Central do Brasil (2021) e de Moreira (2022), fica evidente que a dinâmica da taxa de câmbio do dólar no Brasil envolve muito mais do que apenas o seu histórico linear de preços. Esses estudos confirmam a necessidade de utilizar ferramentas que consigam ler essas relações complexas, o que abre caminho e justifica perfeitamente a adoção de modelos de *Machine Learning* para prever a volatilidade cambial.

2.3.2 Comparações entre paradigmas model-based e data-driven

A literatura empírica, ao testar a robustez dos modelos teóricos em cenários reais, evidenciou a necessidade de maior flexibilidade. Estudos pioneiros, como o de Akgiray (1989), já apontavam que modelos baseados em séries temporais superavam métodos de variância histórica simples. Contudo, a aplicação prática em mercados de alta frequência, como discutido por Moreira e Lemgruber (2004), revelou que a precisão dos modelos model-based é altamente sensível à qualidade do tratamento dos dados, como a filtragem de sazonalidade intradiária.

Nesse contexto, as abordagens data-driven surgiram como uma resposta às limitações dos modelos clássicos na captura de quebras estruturais e relações não lineares. Chung, Espinoza e Quispe (2025) destacam que, em períodos de crises agudas, a rigidez dos modelos GARCH pode levar a redução significativa da capacidade preditiva.Olsen et al. (2025) reforçam esse argumento ao demonstrar que algoritmos baseados em árvores de decisão com otimização de gradiente, como XGBoost, se mostram particularmente eficazes para mapear dependências não lineares e estruturais do mercado, alcançando resultados que frequentemente superam os de modelos econométricos convencionais.

Amoanu (2025) aprofunda essa comparação ao avaliar diretamente o desempenho preditivo de modelos ARIMA, GARCH, Random Forest e XGBoost em séries financeiras, concluindo que os métodos data-driven baseados em árvores apresentam vantagem consistente na captura de padrões não lineares fora da amostra. Ao contrário da abordagem model-based, que prioriza a interpretação dos parâmetros e a robustez estatística sob pressupostos distribicionais, a abordagem data-driven foca na adaptação contínua às relações empíricas dos dados. Assim, a literatura recente sugere que, enquanto os modelos teóricos oferecem base estrutural e interpretabilidade, a flexibilidade dos algoritmos de machine learning é essencial para navegar na complexidade dos mercados contemporâneos.

Capítulo 3

Metodologia

Este capítulo descreve a estratégia metodológica adotada para comparar o desempenho preditivo dos modelos de previsão de volatilidade da taxa de câmbio USD/BRL. O capítulo está organizado em quatro seções. A seção 3.1 apresenta o desenho da pesquisa, definindo o tipo de estudo, o período amostral e os procedimentos de análise descritiva que precedem a estimação dos modelos. A seção 3.2 detalha os modelos propostos, descrevendo as especificações de cada nível (dos modelos de heterocedasticidade condicional ao modelo data-driven) e as decisões de implementação adotadas em cada caso. A seção 3.3 apresenta a estratégia de avaliação fora da amostra, especificando o procedimento de walk-forward com janela expansiva, as métricas de erro utilizadas e o teste de Diebold-Mariano. Por fim, a seção 3.4 registra as principais limitações da estratégia empírica adotada.

3.1 Desenho da pesquisa

Este estudo caracteriza-se como uma pesquisa quantitativa de natureza explicativa. O objetivo é comparar o desempenho preditivo de diferentes classes de modelos de previsão de volatilidade aplicados à taxa de câmbio USD/BRL, avaliando em que condições cada abordagem (model-based ou data-driven) apresenta maior acurácia fora da amostra. A base de dados e o período analisado são descritos no Capítulo 4.

O método de análise é econométrico e estatístico, combinando modelagem de séries temporais (por meio da família GARCH) com aprendizado de máquina supervisionado, representado pelo algoritmo do Random Forest. A comparação entre os modelos é realizada fora da amostra de estimação, com avaliação por funções de perda (MSE e QLIKE) e pelo teste de hipótese de Diebold e Mariano (1995), que permite verificar se as diferenças de desempenho preditivo entre os modelos são estatisticamente significativas.

Para fundamentar a modelagem econométrica e de aprendizado de máquina, a série de retornos log-diários da taxa de câmbio USD/BRL será submetida a um conjunto de testes de hipóteses estatísticas e análises diagnósticas preliminares. Essa etapa busca caracterizar as propriedades estatísticas dos dados e validar o comportamento empírico

(fatos estilizados) que justifica a escolha de modelos adotada.

O procedimento de análise diagnóstica seguirá a seguinte estrutura metodológica:

1. **Estatísticas Descritivas e Testes de Normalidade e Média**: Serão calculados os momentos centrais da série (média, variância, assimetria e excesso de curtose). O afastamento da distribuição normal será avaliado pelo teste de Jarque-Bera (JB), cuja hipótese nula é de normalidade dos retornos (assimetria nula e curtose igual a 3), contra a alternativa de não normalidade.

   Adicionalmente, aplica-se o teste t de Student para avaliar a significância estatística do intercepto da série, sob a hipótese nula de que a média dos retornos é estatisticamente igual a zero ($H_0 : \mu = 0$) contra a hipótese alternativa de que é diferente de zero ($H_1 : \mu \neq 0$).

2. **Teste de Raiz Unitária (Estacionaridade)**: A fim de determinar a ordem de integração da série temporal e evitar o problema de regressão espúria, será utilizado o teste *Augmented Dickey-Fuller* (ADF). O teste avalia a presença de raiz unitária na série em nível (preços) e em primeiras diferenças (retornos), testando:

   H_0: A série possui raiz unitária (é não estacionária).

   H_1: A série não possui raiz unitária (é estacionária).

   Espera-se confirmar que a série de taxas de câmbio é integrada de ordem um, $I(1)$, e que sua primeira diferença é estacionária, $I(0)$.

3. **Teste de Autocorrelação Linear**: Para testar a dependência temporal nos retornos e na variância, aplica-se o teste de Ljung-Box (Q) sobre os retornos diários e sobre os retornos ao quadrado, respectivamente. O teste avalia a hipótese conjunta de ausência de autocorrelação até uma defasagem m:

   H_0: Não há autocorrelação na série até a defasagem m.

   H_1: Existe autocorrelação em pelo menos uma defasagem até m.

   A rejeição de H_0 para os retornos ao quadrado fornece evidência estatística de dependência não linear na variância, confirmando o fenômeno de agrupamento de volatilidade (*volatility clustering*).

4. **Teste de Efeitos ARCH**: A validação da heterocedasticidade condicional, requisito indispensável para a especificação de modelos da família GARCH, será realizada via teste de Multiplicador de Lagrange para efeitos ARCH (ARCH-LM), aplicado diretamente sobre os retornos diários. O teste verifica a existência de estrutura autorregressiva nos quadrados dos retornos, sob as seguintes hipóteses:

H_0: Ausência de efeitos ARCH (a variância condicional é constante).

H_1: Presença de efeitos ARCH (a variância condicional depende do quadrado dos choques passados).

5. **Análise de Correlogramas**: Por fim, a avaliação visual das Funções de Autocorrelação (ACF) e Autocorrelação Parcial (PACF) dos retornos e de seus retornos ao quadrado será adotada como critério complementar de identificação.

3.2 Especificação dos modelos

A estratégia metodológica deste trabalho organiza os modelos em uma hierarquia crescente de complexidade, estruturada em torno da dicotomia entre os paradigmas model-based e data-driven. Os modelos model-based impõem ao processo gerador de dados uma estrutura funcional previamente especificada, garantindo interpretabilidade e robustez estatística sob pressupostos distribicionais. Os modelos data-driven operam sem pressupostos funcionais rígidos, aprendendo as relações diretamente da amostra. A hierarquia é composta por quatro níveis, descritos a seguir.

3.2.1 Modelos de heterocedasticidade condicional: GARCH e EGARCH

A modelagem explícita da variância condicional é feita por meio dos modelos GARCH(1,1) e EGARCH(1,1), estimados diretamente sobre a série de retornos log-diários do USD/BRL. A ordem (1,1) é adotada diretamente, sem busca de defasagens via critério de informação, seguindo Hansen e Lunde (2005), cujos testes sobre séries cambiais diárias demonstram que especificações mais complexas não produzem ganhos preditivos consistentes em relação ao GARCH(1,1). A especificação do GARCH(1,1), conforme Bollerslev (1986), é:

$$\sigma_t^2 = \omega + \alpha\varepsilon_{t-1}^2 + \beta\sigma_{t-1}^2 \tag{3.1}$$

com as restrições $\omega > 0$, $\alpha \geq 0$ e $\beta \geq 0$ e $\alpha + \beta < 1$ para garantir positividade e estacionariedade da variância condicional. A soma $\alpha + \beta$ mede a persistência da volatilidade: valores próximos a 1 indicam que choques têm efeitos duradouros sobre a variância, característica tipicamente observada em séries cambiais.

O EGARCH(1,1), proposto por Nelson (1991), especifica a variância condicional em escala logarítmica, dispensando as restrições de positividade dos parâmetros e permitindo capturar assimetria na resposta da volatilidade a choques positivos e negativos:

$$\ln(\sigma_t^2) = \omega + \alpha \left| \frac{\varepsilon_{t-1}}{\sigma_{t-1}} \right| + \gamma \frac{\varepsilon_{t-1}}{\sigma_{t-1}} + \beta \ln(\sigma_{t-1}^2) \tag{3.2}$$

em que $\frac{\varepsilon_{t-1}}{\sigma_{t-1}}$ é o resíduo padronizado e γ é o parâmetro de assimetria. Um valor $\gamma < 0$ estatisticamente significativo indica que depreciações do real elevam a volatilidade de forma mais intensa do que apreciações de mesma magnitude, hipótese relevante para o mercado cambial brasileiro.

Ambos os modelos são estimados por máxima verossimilhança, com média condicional nula e distribuição t de Student, para acomodar as caudas pesadas dos retornos cambiais. A hipótese de média nula é avaliada pelo teste t da Seção 3.1. Como o GARCH e o EGARCH não são modelos hierárquicos, o teste da razão de verossimilhança não se aplica aqui, a comparação preditiva entre os modelos é feita fora da amostra (Seção 3.3).

3.2.2 Modelo data-driven: Random Forest

O *Random Forest* não impõe estrutura funcional ao processo gerador de dados. Diferentemente dos modelos anteriores, o *Random Forest* opera como problemas de aprendizado supervisionado, em que a variável dependente é a *proxy* de volatilidade (r_t^2) e as variáveis independentes são um vetor de *features* construídas a partir do histórico da série. As features são descritas na Seção 4.2.

O *Random Forest* será treinado com $B = 500$ árvores, profundidade máxima de 5 níveis e no minimo 5 observações por folha. A cada divisão, um subconjunto de $\lfloor\sqrt{K}\rfloor = 3$ variáveis, será sorteado, esse valor foi popularizado por Breiman (2001) e reduz a correlação entre as árvores. Os hiperparâmetris foram fixados de antemão, de modo que a avaliação fora da amostra não é contaminada por um processo de seleção de moledos. A semente aleatória é fixa (42) para garantir a reprodutibilidade dos resultados.

3.3 Estratégia de avaliação fora da amostra

A avaliação do desempenho preditivo dos modelos será realizada fora da amostra de estimação, por meio de um esquema de previsão com origem móvel (rolling-origin). Conforme discutido por Tashman (2000), esse procedimento permite avaliar a capacidade preditiva dos modelos em diferentes origens de previsão, aproximando a avaliação das condições enfrentadas em aplicações reais.

Na análise principal, será utlizada uma janela expansiva (expanding window). Nessa abordagem, o modelo é estimado com todas as observações disponíveis até o período t e produz previsão para t + 1; em seguida, a janela de estimação é expandida com a nova observação e o processo se repete. Essa estratégia permite preservar todo o histórico disponível, possibilitando que os modelos utilizem informações de diferentes regimes de volatilidade ao longo do período analisado.

Os modelos GARCH e EGARCH são reestimados a cada observação, entretanto o *Random Forest* é reestimado a cada cinco dias úteis, por custo computacional. Entre

as reestimações, o *Random Forest* não é retreinado, mas recebe diariamente as features atualizadas, mantendo as previsões de um passo à frente.

A amostra será dividida em dois subperíodos: janeiro de 2000 a dezembro de 2019 como janela de estimação inicial (aproximadamente 75% das observações) e janeiro de 2020 a maio de 2026 como janela de avaliação fora da amostra (aproximadamente 25% das observações). Essa divisão é deliberada: o subperíodo de avaliação concentra os episódios de maior estresse cambial recente, o choque da pandemia de COVID-19, o ciclo de alta do dólar de 2021-2022, a incerteza fiscal de 2023-2024 e os desdobramentos macroeconômicos até 2026, permitindo avaliar o desempenho preditivo dos modelos precisamente sob sucessivas quebras estruturais e condições adversas de mercado.

Adicionalmente, como análise de robustez, será utilizada uma janela rolante (rolling window) de cinco anos, na qual apenas as observações mais recentes são mantidas no conjunto de estimação, enquanto as mais antigas são progressivamente excluídas, conforme o procedimento de janela de tamanho fixo descrito por Tashman (2000). A comparação entre as duas estratégias permite investigar a sensibilidade dos resultados em relação a quantidade e à qualidade das informações recentes utilizadas na estimação, questão particularmente relevante diante da possibilidade de mudanças estruturais nas séries econômicas (Pesaran e Timmermann, 2007).

O desempenho preditivo é avaliado sobre a janela de avaliação fora da amostra, com N observações. O r^2 é a proxy de variância no dia t e $\hat{h}_t$ a variância prevista pelo modelo para o mesmo dia, calculada com informação disponível até t - 1. A comparação principal utiliza as seguintes medidas:

- Erro Quadrático Médio (MSE): média de $\frac{1}{N}\sum_{t=1}^{N}\left(r_t^2 - \hat{h}_t\right)^2$. Penaliza erros grandes de forma quadrática, sendo mais sensível a episódios de alta volatilidade;

- QLIKE: média de $\frac{1}{N}\sum_{t=1}^{N}\left(\ln \hat{h}_t + \frac{r_t^2}{\hat{h}_t}\right)$. É uma função de perda específica para previsões de variância que penaliza de forma assimétrica a subestimação da variância e é menos dominada por poucas observações extremas do que o MSE;

- Teste de Diebold-Mariano (DM): teste de hipótese que avalia se a diferença entre as funções de perda de dois modelos é estatisticamente significativa, com H_0 de que as perdas esperadas são iguais (Diebold e Mariano, 1995). Para cada par de modelos, o teste é aplicado à diferença diária entre as perdas, $d_t = L_{A,t} - L_{B,t}$, separadamente para o MSE e para o QLIKE. Foi utilizado a correção para amostras finitas de Harvey, Leybourne e Newbold (1997), com p-valores baseados na distribuição t de Student com N - 1 graus de liberdade (estatística é chamada de DM-HLN nas tabelas). Além disso, a variância da diferença de perdas é estimada de forma robusta a heterocedasticidade e autocorrelação (Newey e West, 1987), com o número de defasagens dado por $\left\lfloor 4\,(N/100)^{2/9} \right\rfloor$ (Newey e West, 1994)

Como a variância real é uma *proxy* calculada a partir do retorno ao quadrado, uma medida ruidosa, foram usados funções de perda (MSE e QLIKE) cujo ranking de modelos não é distorcido por esse ruído (Patton, 2011). RMSE e MAE são reportados apenas como medidas complementares.

Para as métricas MSE e QLIKE, valores menores indicam melhor desempenho preditivo. No caso do QLIKE, portanto, valores mais negativos representam menores perdas e, consequentemente, previsões relativamente melhores. Já o RMSE e o MAE, também devem ser interpretados de acordo com o critério de minimização.

Ademais, como no teste Diebold-Mariano a hipótese nula estabelece que os dois modelos apresentam perdas esperadas iguais, p-valores inferiores ao nível de significância adotado indicam diferenças estatisticamente significativas entre os modelos. O sinal da estatística DM-HLN indica a direção dessa diferença, considerando a ordem dos modelos na comparação, em que valores negativos favorecem o Modelo A, enquanto valores positivos favorecem o Modelo B.

3.4 Limitações

Este estudo apresenta algumas limitações que devem ser registradas. A primeira diz que a proxy de volatilidade adotada, o retorno ao quadrado (r_t^2), é uma medida ruidosa da volatilidade latente, pois combina variância condicional e o quadrado da inovação. Em estudos com dados intradiários, seria possível calcular a volatilidade realizada de forma mais precisa, no entanto, a disponibilidade de dados diários de fechamento é suficiente para o escopo deste trabalho e é o padrão adotado na literatura comparativa com modelos GARCH.

Outras limitações vêm do próprio Random Forest, que não possui estrutura de memória temporal interna, dependendo inteiramente da engenharia de features para capturar a dinâmica serial da volatilidade. A escolha das defasagens e variáveis incluídas no vetor de features introduz um grau de subjetividade que modelos econométricos tradicionais evitam por construção. Há ainda a diferença na frequência de reestimação, em que o RandomForest é reestimado a cada cinco dias úteis, enquanto o GARCH e o EGARCH são reestimados diariamente. Essa assimetria, se houver algum efeito, é contra o Random Forest, que passa até quatro dias defasado.

Por fim, a análise é restrita à previsão de um passo à frente (one-step-ahead), não abrangendo horizontes mais longos. A extensão para múltiplos horizontes, bem como a incorporação de variáveis exógenas, como o índice VIX, o diferencial de juros Brasil-EUA e o CDS soberano brasileiro, constituem agenda para pesquisas futuras.

Capítulo 4

Base de Dados e Estrategia Empirica

Este capítulo apresenta os dados utilizados na análise e os procedimentos adotados para sua preparação. Inicialmente, são descritas a fonte e as características da série histórica da taxa de câmbio USD/BRL, assim como a delimitação do período de estudo. Em seguida, são apresentadas a construção da variável dependente e das variáveis explicativas utilizadas nos modelos, considerando cada abordagem. Por fim, são detalhados os procedimentos de tratamento dos dados, incluindo a identificação de observações ausentes, a organização cronológica da série e os critérios adotados para a definição da amostra utilizada nas estimações.

4.1 Fontes de dados

A unidade de análise é o retorno diário da taxa de câmbio USD/BRL, calculado a partir da série DEXBZUS (Brazil / U.S. Foreign Exchange Rate), obtida junto ao Federal Reserve Bank of St. Louis (FRED) em 23 de outubro de 2026, e o período estudado compreende janeiro de 2000 até maio de 2026 (última observação disponível: 29 de maio de 2026). O recorte temporal inicia após a consolidação do regime de câmbio flutuante, implementado em janeiro de 1999, de forma a excluir o período de transição cambial e garantir homogeneidade institucional da série. O período cobre episódios relevantes de estresse cambial, incluindo a crise de confiança de 2002, a crise financeira global de 2008, a recessão brasileira de 2015-2016, o choque da pandemia de COVID-19 em 2020 e o ciclo de incerteza fiscal de 2021-2024.

4.2 Construcao das variaveis

A variável dependente é a proxy de volatilidade, o retorno ao quadrado (r_t^2), em que $r_t = \ln\left(\frac{P_t}{P_{t-1}}\right)$ é o log-retorno diário e P_t é a taxa de câmbio USD/BRL. Para a estimação do GARCH e do EGARCH, os retornos são multiplicados por 100 (pontos percentuais), e

as previsões são convertidas de volta à escala de r_t^2, antes da comparação entre modelos.

As variáveis explicativas do *Random Forest* são construídas exclusivamente a partir do histórico da própria série, e todas utilizam apenas informação disponível até $t-1$. O vetor de *features*, com $K = 14$ variáveis, é composto por:

- Retornos log-diários defasados: $r_{t-1}, r_{t-2}, \ldots, r_{t-5}$;
- *Proxies* de volatilidade defasadas: $r_{t-1}^2, r_{t-2}^2, \ldots, r_{t-5}^2$;
- Médias móveis do retorno absoluto em janelas de $w \in \{5, 21\}$ dias: $\frac{1}{w}\sum_{j=1}^{w} |r_{t-j}|$;
- Volatilidade histórica de 21 dias: desvio-padrão amostral de $r_{t-1}, \ldots, r_{t-21}$;
- Índice de Força Relativa (RSI) de 14 dias, calculado sobre os retornos log-diários com médias simples de ganhos e perdas (sem a suavização de Wilder) e defasado em um período.

Os modelos da família GARCH utilizam apenas os retornos passados. Não são incluídas variáveis de controle exógenas.

4.3 Tratamento dos dados

A série bruta foi preservada sem alterações, com as observações ausentes mantidas, e as datas sem cotação foram registradas em arquivo separado (269 datas). Essas datas foram excluídas da amostra, sem interpolação, e o retorno foi calculado entre observações consecutivas disponíveis. Assim, um retorno que atravessa um fim de semana ou feriado cobre mais de um dia corrido. Foi verificado, também, a ausência de datas duplicadas e a ordenação cronológica, e a amostra foi truncada em 31 de maio de 2026, com última observação em 29 de maio. Não foram aplicados filtros de exclusão de outliers.

Capítulo 5

Resultados

Este capítulo apresenta os resultados obtidos na análise empírica, iniciando pela caracterização das propriedades estatísticas da série de retornos cambiais e de sua volatilidade. Em seguida, são apresentados e discutidos os resultados das previsões realizadas pelos modelos Random Forest, GARCH e EGARCH, considerando as métricas de desempenho e os testes de comparação preditiva. Por fim, é realizada uma análise de robustez por meio da substituição da janela expansiva por uma janela rolante de cinco anos, com o objetivo de avaliar a sensibilidade dos resultados a essa alteração na estratégia de estimação.

5.1 Análise descritiva

Esta seção apresenta a análise descritiva da série de retornos log-diários da taxa de câmbio USD/BRL, cobrindo o período de janeiro de 2000 a maio de 2026. O objetivo é caracterizar empiricamente as propriedades estatísticas da série e validar os chamados fatos estilizados das finanças, que fundamentam a escolha de modelos adotados.

O gráfico da série de câmbio USD/BRL em nível mostra uma trajetória ascendente ao longo do período amostral, como mostra a figura 5.1:

Partindo de valores próximos a R$ 1,80/US$ no início do ano de 2000, a taxa atingiu níveis superiores a R$ 6,00/US$ nos anos recentes, evidenciando uma tendência estocástica de longo prazo. A decomposição sazonal da série, apresentada na Figura A.1 do Apêndice A, confirma visualmente a presença de tendência crescente e componente sazonal, com o resíduo concentrando os movimentos abruptos associados a eventos de estresse. Esses elementos são consistentes com a hipótese de que a série de câmbio é não estacionária em nível, o que é verificado formalmente pelo teste ADF na tabela 5.1.

A série de retornos log-diários (Figura A.3 do Apêndice A) apresenta comportamento distinto do nível da taxa de câmbio, com oscilações em torno de zero e variância que se altera ao longo do tempo. Esse comportamento também pode ser observado na volatilidade histórica móvel de 21 dias (Figura 5.2), que evidencia episódios de maior volatilidade, especialmente em 2002, 2008, 2015–2016 e 2020, intercalados por períodos de relativa

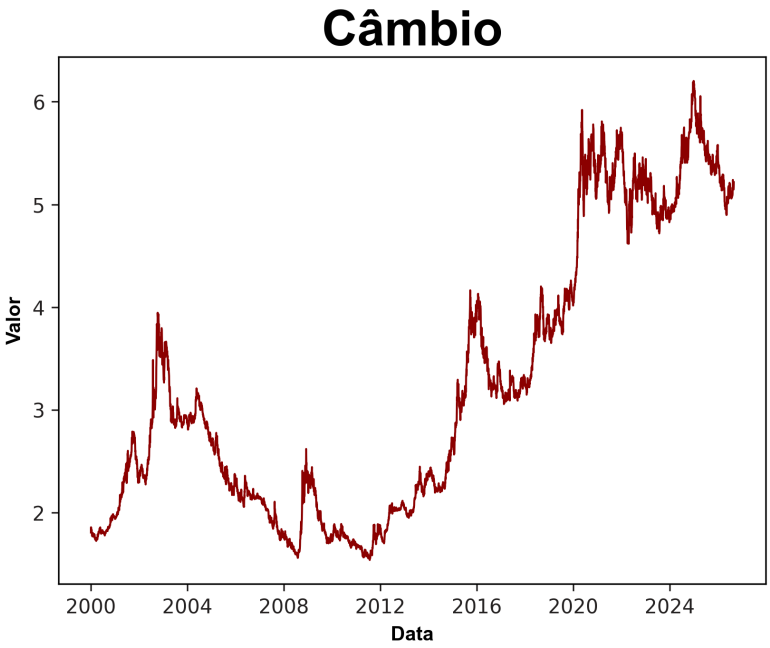


Figura 5.1: Série do càmbio

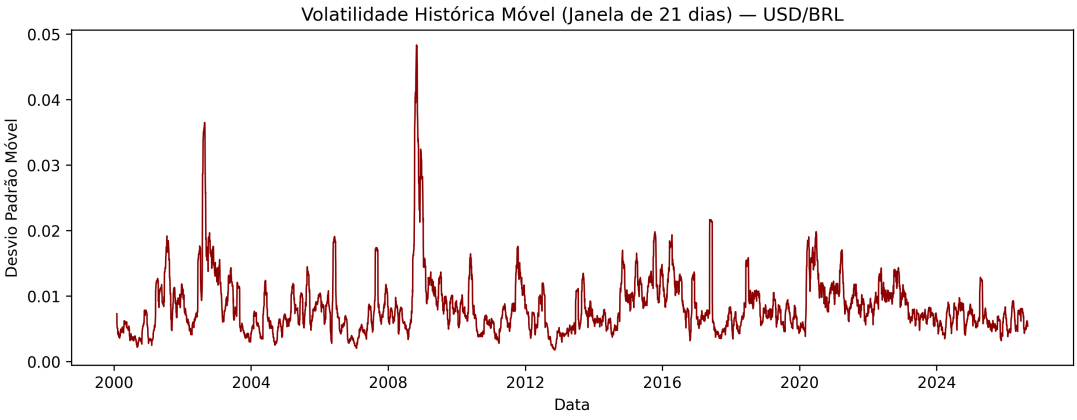


Figura 5.2: Volatilidade móvel de 21 dias

calmaria. Essa alternância, denominada clustering de volatilidade, é um dos fatos estilizados das séries financeiras e constitui uma das principais motivações para a adoção de modelos da família GARCH.

Tabela 5.1: Testes de estacionariedade e heterocedasticidade

Teste	Estatística	p-valor
ADF (câmbio em nível)	-0,760	0,8305
ADF (retornos)	-14,025	$< 0,001$
Ljung–Box (retornos ao quadrado, lag 10)	4685,152	$< 0,001$
ARCH	1669,466	$< 0,001$

Nota: O teste ADF tem como hipótese nula a presença de raiz unitária. O teste Ljung–Box testa a ausência de autocorrelação até a defasagem considerada, enquanto o teste ARCH testa a ausência de efeitos ARCH.

Os testes de estacionariedade indicam que não se rejeita a hipótese nula de raiz unitária para a taxa de câmbio em nível (p-valor = 0,831), enquanto essa hipótese é rejeitada para os retornos log-diários (p-valor $<$ 0,001). Esses resultados são compatíveis com a não estacionariedade da série em nível e a estacionariedade dos retornos, que são utilizados nas etapas seguintes da análise.

Conforme apresentado na Tabela A.2 do Apêndice A, a distribuição dos retornostem média próxima de zero (0,000156) e baixa assimetria (0,026), mas curtose de 7,994, indicando uma distribuição com caudas mais pesadas diferentes de uma distribuição normal. O teste de Jarque-Bera rejeita a hipótese de normalidade (p-valor $<$ 0,001), resultado também ilustrado pela comparação entre a densidade empírica e a normal teórica na Figura A.5 do Apêndice A. Além disso, o teste t não rejeita a hipótese de média igual a zero (p-valor = 0,205). Em conjunto, esses resultados mostram como funciona a distribuição dos retornos e são relevantes para a especificação dos modelos de volatilidade.

Por fim, o teste de Ljung-Box aplicado aos retornos ao quadrado rejeita a hipótese de ausência de autocorrelação tanto para 10 quanto para 20 defasagens (p-valores $<$ 0,001). O teste ARCH também rejeita a hipótese nula de ausência de efeitos ARCH (p-valor $<$ 0,001). Essas evidências apontam para dependência temporal na volatilidade e sustentam o uso de modelos da família GARCH. Os correlogramas dos retornos e dos retornos ao quadrado, apresentados na Figura A.2 do Apêndice A, complementam essa análise. Os resultados completos dos testes estatísticos são apresentados na Tabela A.1 do Apêndice A.

5.2 Resultados principais

A Tabela 5.2 apresenta as métricas de desempenho preditivo dos modelos estimados. De maneira geral, o Random Forest apresentou os melhores resultados em termos de MSE, RMSE e QLIKE, enquanto o EGARCH obteve o menor MAE. Embora as diferenças

Tabela 5.2: Desempenho preditivo dos modelos

Modelo	MSE	RMSE	MAE	QLIKE
RF	$2{,}604 \times 10^{-8}$	0,000161	0,000093	−8,457
EGARCH	$2{,}643 \times 10^{-8}$	0,000163	0,000092	−8,451
GARCH	$2{,}664 \times 10^{-8}$	0,000163	0,000094	−8,448

Fonte: Elaboração própria.

entre os valores sejam relativamente pequenas, o desempenho do Random Forest indica uma vantagem numérica na previsão da variância cambial, especialmente considerando as métricas que penalizam erros de previsão de forma mais sensível como o MSE.

Em relação aos modelos da família GARCH, o EGARCH apresentou resultados ligeiramente superiores ao GARCH nas quatro métricas consideradas, com exceção do MAE, no qual também obteve o melhor resultado entre os três modelos. Esse resultado sugere que a especificação assimétrica do EGARCH pode oferecer alguma vantagem na representação da dinâmica da volatilidade cambial, embora essa diferença seja pequena.

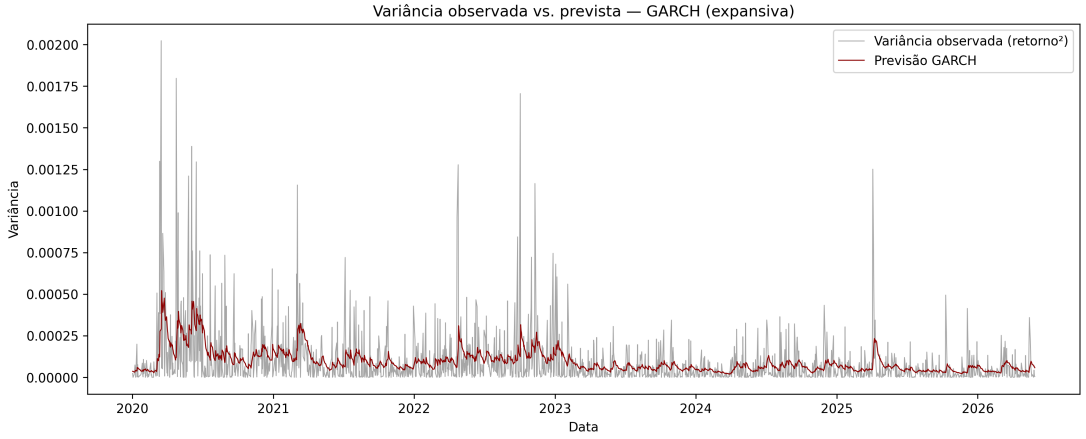


Figura 5.3: Variância observada e prevista pelo modelo GARCH(1,1) — janela expansiva

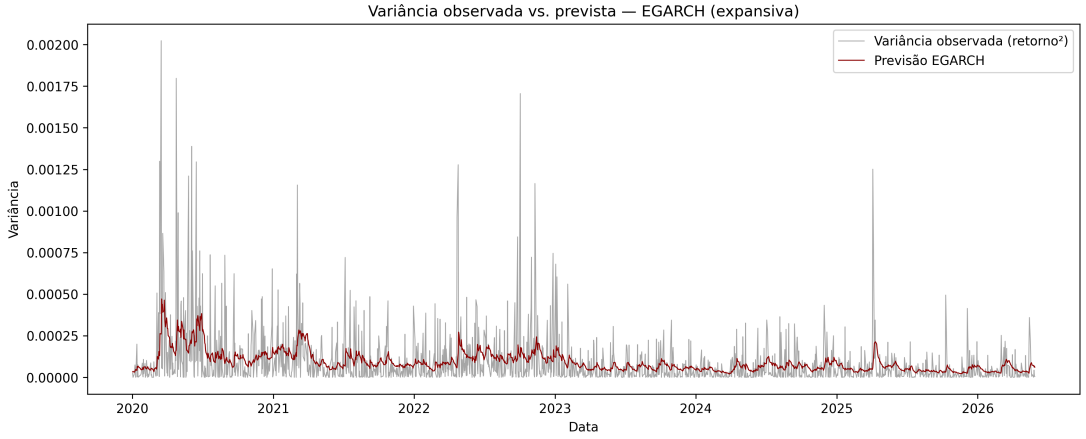


Figura 5.4: Variância observada e prevista pelo modelo EGARCH(1,1) — janela expansiva

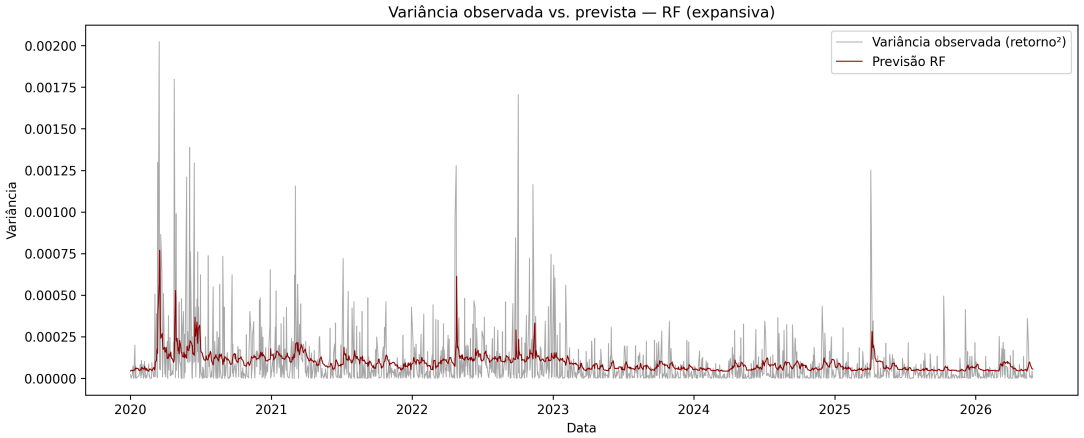


Figura 5.5: Variância observada e prevista pelo modelo Random Forest — janela expansiva

A análise gráfica das variâncias observadas e previstas, apresentada nas Figuras 5.3 a 5.5, permite complementar a comparação. É possível notar que os três modelos conseguem acompanhar parcialmente a dinâmica da volatilidade ao longo do período analisado, identificando momentos de maior instabilidade. Entretanto, é possível identificar, também, que o Random Forest apresenta uma capacidade relativamente maior de acompanhar alguns dos picos de volatilidade, especialmente nos períodos de maior instabilidade. Apesar disso, as previsões dos três modelos apresentam um comportamento mais suavizado em comparação com a variância observada, evidenciando dificuldades em representar integralmente os movimentos extremos. Assim, embora o Random Forest apresente uma resposta visualmente mais próxima da variância observada em determinados momentos, essa característica não se traduz em uma superioridade estatisticamente significativa, conforme indicado pelos testes de Diebold-Mariano.

Além das métricas de desempenho, a tabela B.3 no Apêndice B mostra a importância das variáveis utilizadas pelo modelo Random Forest, com o objetivo de identificar quais atributos contribuíram mais para suas previsões. Na janela expansiva, a média móvel dos retornos absolutos em cinco dias apresentou a maior importância (0,163), seguida pelo retorno defasado em um período (0,118) e pela volatilidade defasada em um período (0,105). Também se destacaram a média móvel dos retornos absolutos em 21 dias e a volatilidade histórica de 21 dias. Esses resultados indicam a relevância das informações recentes de retorno e das medidas de volatilidade passada para as previsões do modelo.

Por fim, os resultados dos testes de Diebold-Mariano com a correção de Harvey, Leybourne e Newbold, apresentados nas Tabelas 5.3 e 5.4, não apontaram diferenças estatisticamente significativas entre os modelos, tanto para a função de perda MSE quanto para a QLIKE. Em todas as comparações, os p-valores foram superiores a 0,05, ou seja, não foi possível rejeitar a hipótese nula de igualdade de desempenho preditivo. Dessa forma, apesar da vantagem numérica observada para o Random Forest em algumas métricas, não há evidências estatísticas suficientes para afirmar que seu desempenho preditivo seja

Tabela 5.3: Teste Diebold–Mariano para a função de perda MSE

Modelo A	Modelo B	DM-HLN	p-valor
RF	GARCH	-1,128	0,259
RF	EGARCH	-0,700	0,484
GARCH	EGARCH	0,932	0,351

Fonte: Elaboração própria.

Tabela 5.4: Teste Diebold–Mariano para a função de perda QLIKE

Modelo A	Modelo B	DM-HLN	p-valor
RF	GARCH	-0,827	0,408
RF	EGARCH	-0,525	0,600
GARCH	EGARCH	0,440	0,660

Fonte: Elaboração própria.

superior ao dos modelos GARCH e EGARCH.

Em conjunto, os resultados indicam que tanto os modelos econométricos da família GARCH quanto o Random Forest foram capazes de produzir previsões competitivas para a volatilidade cambial. A ausência de diferenças estatisticamente significativas sugere que a maior flexibilidade do Random Forest não se traduziu, nessa análise, em uma superioridade preditiva estatisticamente comprovada.

Resultados complementares das estimações dos modelos GARCH e EGARCH, incluindo os coeficientes estimados e suas respectivas estatísticas, são apresentados nas Seções B.1 e B.2 do Apêndice B. O apêndice também apresenta a importância das variáveis utilizadas pelo Random Forest (Seção B.3), permitindo identificar aquelas que mais contribuíram para as previsões, bem como os resultados completos dos testes Diebold-Mariano para as funções de perda MSE e QLIKE (Seção B.4).

5.3 Testes de robustez

Para avaliar a robustez dos resultados obtidos na análise principal, foi realizada uma análise complementar utilizando uma janela rolante de cinco anos, em substituição à janela expansiva. Essa especificação permite verificar se o desempenho relativo dos modelos se mantém quando as estimações consideram apenas as observações mais recentes, atribuindo maior relevância às condições de mercado próximas ao período de previsão. A comparação foi realizada entre os modelos Random Forest e GARCH, conforme os resultados apresentados a seguir.

Na análise de robustez com janela rolante de cinco anos, o modelo EGARCH foi excluído

devido à instabilidade observada no seu processo de estimação. Foram identificados episódios de não convergência do algoritmo de otimização e, mesmo em estimações com convergência reportada, ocorreram previsões de variância excessivamente elevadas. Esses problemas comprometeram a confiabilidade das previsões e motivaram a exclusão do modelo dessa especificação. Os diagnósticos das estimações são apresentados nas Tabelas B.6 e B.7 do Apêndice B.

Tabela 5.5: Desempenho preditivo dos modelos — janela rolante

Modelo	MSE	RMSE	MAE	QLIKE
GARCH	$2{,}614 \times 10^{-8}$	0,000162	0,000091	−8,458
RF	$2{,}700 \times 10^{-8}$	0,000164	0,000095	−8,435

Fonte: Elaboração própria.

A Tabela 5.5 apresenta as métricas de desempenho preditivo dos modelos estimados com janela rolante de cinco anos. De maneira geral, o GARCH apresentou os melhores resultados nas quatro métricas consideradas, obtendo menores valores de MSE, RMSE e MAE, além de um QLIKE mais negativo. Embora as diferenças entre os valores sejam relativamente pequenas, os resultados indicam uma vantagem numérica do GARCH em relação ao Random Forest na previsão da variância cambial. Dessa forma, diferentemente do observado na janela expansiva, em que o Random Forest apresentou os melhores resultados em algumas métricas, a especificação com janela rolante favoreceu o modelo GARCH.

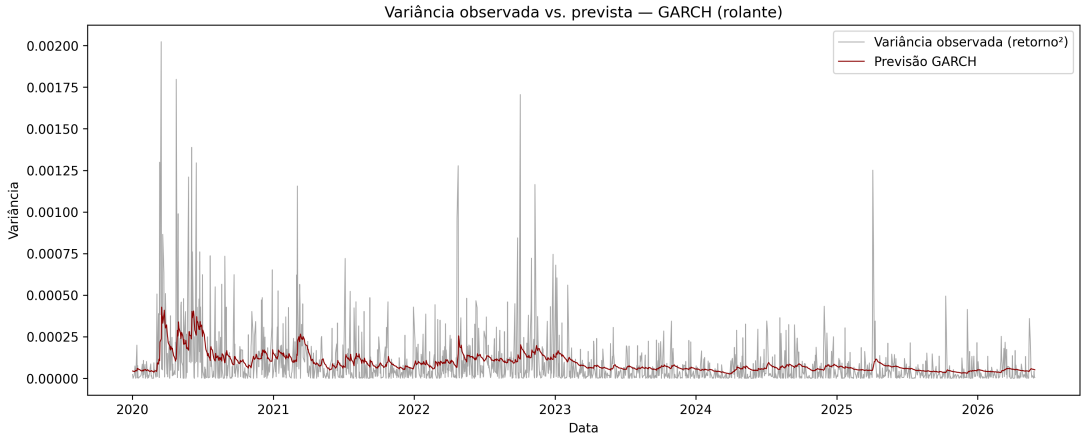


Figura 5.6: Variância observada e prevista pelo modelo GARCH(1,1) — janela rolante

As Figuras 5.6 e 5.7 apresentam as variâncias observadas e previstas pelos modelos GARCH e Random Forest, respectivamente, considerando a janela rolante de cinco anos. De maneira geral, ambos os modelos conseguem acompanhar parte da dinâmica da volatilidade cambial, identificando períodos de maior instabilidade e apresentando previsões mais elevadas nos momentos de maior volatilidade observada.

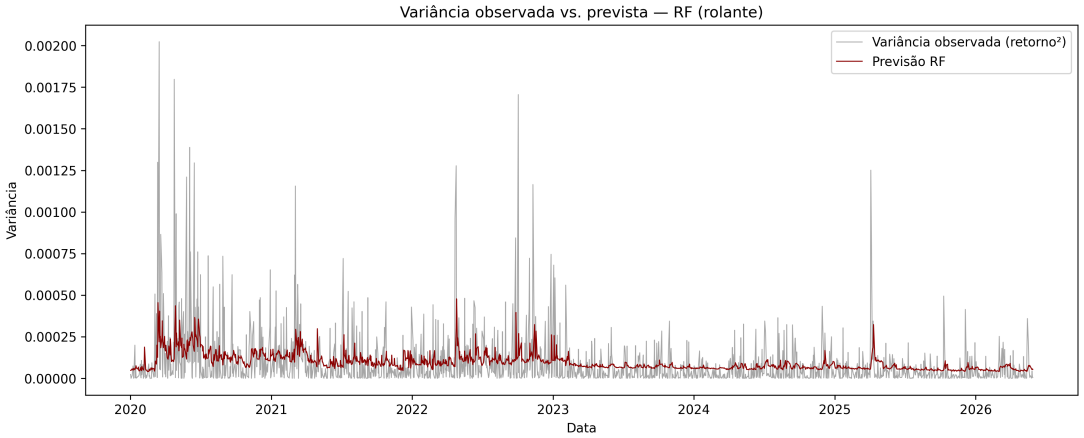


Figura 5.7: Variância observada e prevista pelo modelo Random Forest — janela rolante

Entretanto, é possível notar que as previsões dos dois modelos apresentam dificuldades em acompanhar a magnitude dos picos mais acentuados da variância observada. O GARCH apresenta uma trajetória de previsão relativamente mais suave, enquanto o Random Forest demonstra uma maior oscilação nas previsões, reagindo de maneira mais pronunciada a algumas variações da série. Apesar dessas diferenças visuais, ambos apresentam limitações na antecipação de movimentos extremos.

Além disso, a tabela B.8 do Apêndice B, mostra importância das variáveis utilizadas pelo modelo Random Forest, com o objetivo de identificar quais atributos contribuíram mais as previsões considerando a janela rolante. Conforme apresentado na tabela, os retornos defasados e as medidas de volatilidade passada tiveram destaque entre as dez variáveis mais importantes. Em particular, o retorno defasado em cinco períodos apresentou a maior importância (0,109), seguido pela volatilidade defasada em cinco períodos (0,100) e pelo retorno defasado em um período (0,100). Também se destacaram a volatilidade histórica de 21 dias e a média móvel dos retornos absolutos em 21 dias. Diferentemente da janela expansiva, em que as médias móveis dos retornos absolutos ocuparam posições de maior destaque, na janela rolante as variáveis de retorno e volatilidade defasados apresentaram maior importância relativa.

Tabela 5.6: Teste Diebold-Mariano para a janela rolante

Modelo A	Modelo B	Perda	DM-HLN	p-valor
RF	GARCH	MSE	2,547	0,011
RF	GARCH	QLIKE	2,376	0,018

Nota: Ambas as comparações utilizam 1.602 observações.
Fonte: Elaboração própria.

Os resultados do teste Diebold-Mariano, apresentados na Tabela 5.6, indicam diferenças estatisticamente significativas entre os modelos para ambas as funções de perda. Para o

MSE, a estatística DM-HLN foi de 2,547, com p-valor de 0,011, enquanto para o QLIKE foi de 2,376, com p-valor de 0,018. Em ambos os casos, a hipótese nula de igualdade de desempenho preditivo é rejeitada ao nível de significância de 5%. Considerando que as diferenças médias de perda foram calculadas como RF menos GARCH, os resultados favorecem o modelo GARCH, corroborando sua superioridade observada nas métricas de desempenho.

Por fim, a análise de robustez mostra que a escolha da janela de estimação influencia o desempenho relativo dos modelos. Enquanto na especificação com janela expansiva o Random Forest apresentou os menores valores de MSE e QLIKE, embora sem diferenças estatisticamente significativas em relação aos demais modelos, na janela rolante de cinco anos o GARCH apresentou desempenho superior ao Random Forest nas duas funções de perda consideradas. Uma possível explicação é que a janela expansiva, ao incorporar um histórico mais amplo de observações, oferece ao Random Forest uma base maior para identificar padrões na série, enquanto a janela rolante restringe a estimação às informações mais recentes. Dessa forma, os resultados sugerem que a relação entre o desempenho preditivo e a estratégia de estimação merece atenção na escolha dos modelos de previsão da volatilidade cambial.

Capítulo 6

Conclusão

6.1 Sintese dos resultados

Este trabalho teve como objetivo avaliar o desempenho de diferentes modelos na previsão da volatilidade da taxa de câmbio USD/BRL, comparando uma abordagem de aprendizado de máquina, representada pelo Random Forest, com modelos tradicionais da família GARCH, especificamente GARCH e EGARCH.

Os resultados da análise empírica evidenciaram a presença de características típicas de séries financeiras nos retornos cambiais, como não normalidade e dependência temporal nos retornos ao quadrado, reforçando a relevância da modelagem da volatilidade. Na comparação dos modelos, considerando a janela expansiva, o Random Forest apresentou os menores valores de MSE e QLIKE, enquanto o EGARCH obteve o menor MAE. Apesar dessas diferenças numéricas, os testes Diebold-Mariano não identificaram diferenças estatisticamente significativas entre os modelos para nenhuma das duas funções de perda consideradas. Portanto, não foram encontradas evidências de superioridade preditiva estatística de um modelo em relação aos demais nessa especificação.

Na análise de robustez, a substituição da janela expansiva por uma janela rolante de cinco anos alterou o desempenho relativo dos modelos. Nessa configuração, o GARCH apresentou os melhores resultados em todas as métricas avaliadas, com diferenças estatisticamente significativas em relação ao Random Forest, conforme os testes Diebold-Mariano para MSE e QLIKE. Esse resultado demonstra que o desempenho preditivo dos modelos depende também da estratégia de estimação adotada, não sendo possível estabelecer uma superioridade independente dessa escolha.

6.2 Contribuições

A principal contribuição deste estudo consiste na comparação empírica entre modelos econométricos tradicionais e uma abordagem de aprendizado de máquina na previsão da

volatilidade cambial brasileira. Além da avaliação por diferentes métricas de desempenho, foram utilizados testes de comparação preditiva com a correção de Harvey-Leybourne-Newbold (HLN), buscando conferir maior rigor à análise das diferenças entre os modelos.

Do ponto de vista aplicado, o estudo contribui para a discussão sobre a utilização de métodos de aprendizado de máquina em problemas de previsão financeira, especialmente em comparação com modelos econométricos amplamente utilizados na literatura. Os resultados também oferecem subsídios para a escolha de abordagens de previsão em aplicações relacionadas à análise de risco e ao acompanhamento da volatilidade cambial.

6.3 Agenda futura

As limitações identificadas ao longo deste estudo oferecem oportunidades para o desenvolvimento de pesquisas futuras. Uma primeira possibilidade consiste na utilização de medidas alternativas de volatilidade, especialmente a volatilidade realizada calculada a partir de dados intradiários, permitindo uma aproximação mais precisa da volatilidade latente e uma avaliação da sensibilidade dos resultados à proxy adotada neste trabalho.

Outra extensão seria explorar diferentes configurações do Random Forest, incluindo a seleção de variáveis, a construção de novas features e a frequência de reestimação do modelo. A investigação de outras abordagens de aprendizado de máquina, como o XGBoost, que incorporem mecanismos de dependência temporal também poderia contribuir para a comparação com os modelos econométricos tradicionais.

Além disso, seria interessante ampliar a análise para horizontes de previsão superiores a um dia, verificando se o desempenho relativo dos modelos se mantém em previsões de médio prazo. A incorporação de variáveis exógenas, como o índice VIX, o diferencial de juros entre Brasil e Estados Unidos e o CDS soberano brasileiro, também é uma possibilidade de investigação, permitindo avaliar se informações adicionais contribuem para melhorar a capacidade preditiva dos modelos.

Por fim, a realização de análises em diferentes subperíodos e a investigação de outras estratégias de estimação poderiam aprofundar a compreensão sobre a sensibilidade dos modelos às mudanças nas condições de mercado, especialmente diante de episódios de maior instabilidade cambial.

Apêndice A

Resultados complementares

A.1 Gráficos complementares

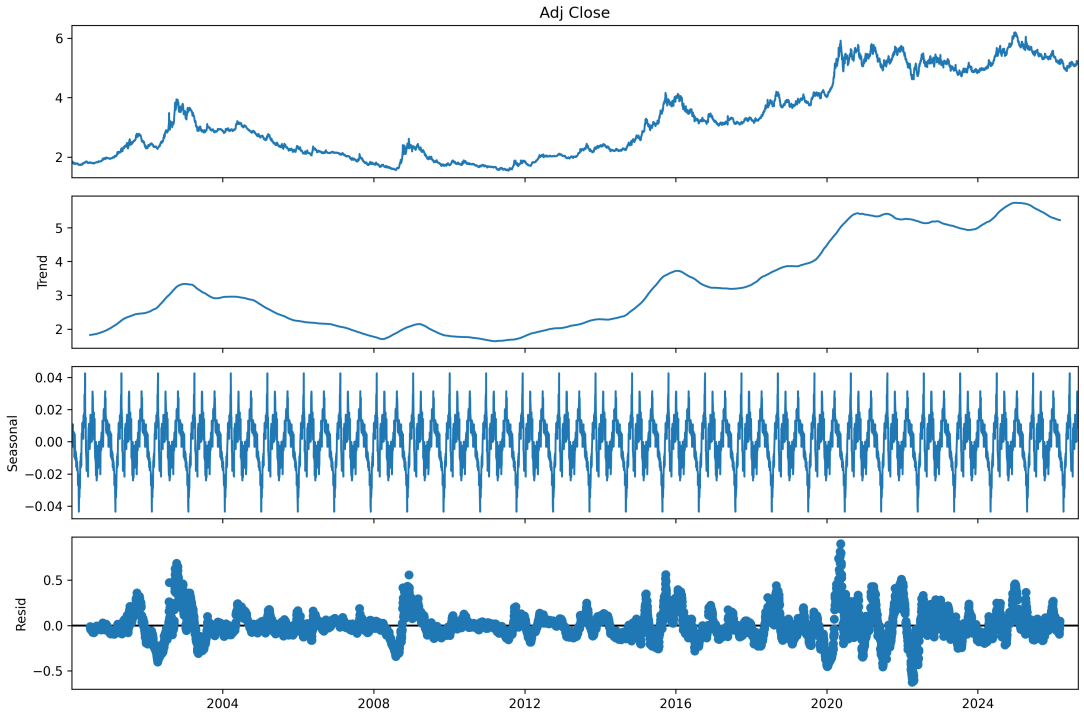


Figura A.1: Decomposição da série cambial USD/BRL

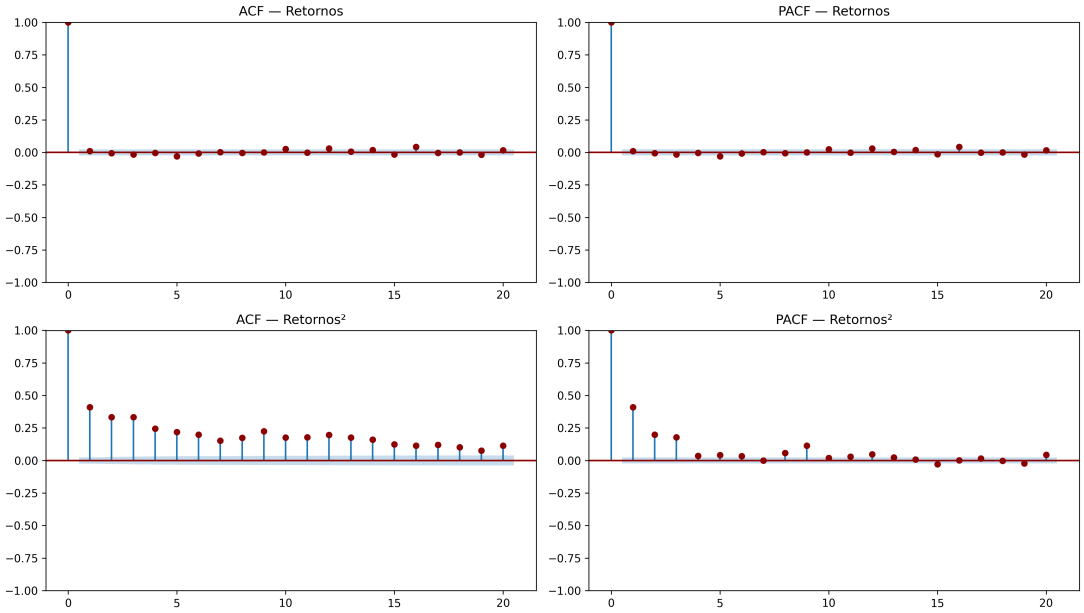


Figura A.2: Funções de autocorrelação (ACF e PACF) dos retornos e dos retornos ao quadrado

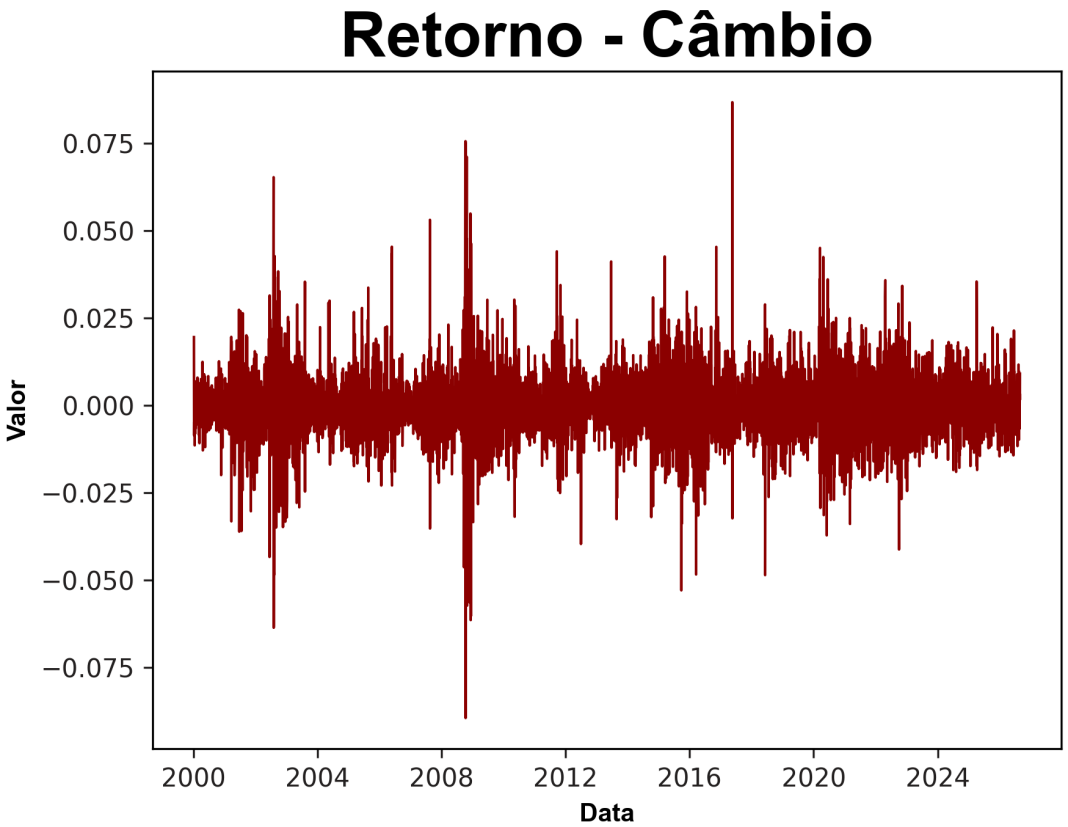


Figura A.3: Retornos logarítmicos diários da taxa de câmbio USD/BRL

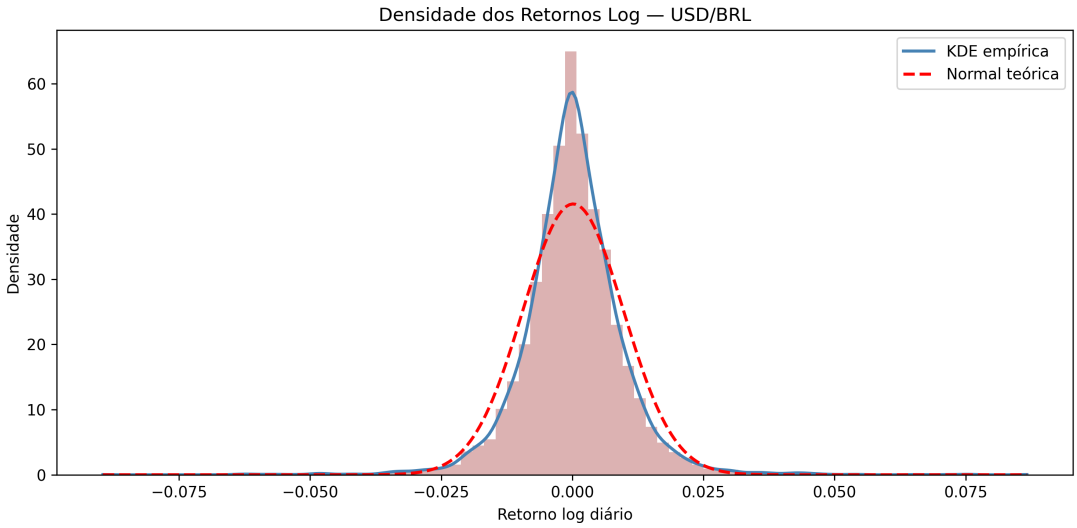


Figura A.4: Distribuição dos retornos logarítmicos diários do USD/BRL

A.2 Resultados dos testes estatísticos

Tabela A.1: Resultados dos testes estatísticos e momentos dos retornos

Teste ou medida	Estatística / Valor	p-valor
ADF (câmbio em nível)	-0,7603	0,8305
ADF (retornos)	-14,0249	$< 0,001$
Teste t (média = 0)	1,2680	0,2048
Jarque–Bera	17596,8174	$< 0,001$
Ljung–Box (retornos, lag 10)	22,1757	0,0142
Ljung–Box (retornos, lag 20)	50,6874	0,0002
Ljung–Box (retornos ao quadrado, lag 10)	4685,1518	$< 0,001$
Ljung–Box (retornos ao quadrado, lag 20)	5889,8042	$< 0,001$
ARCH	1669,4662	$< 0,001$
Média	0,000156	—
Variância	0,0000998	—
Desvio-padrão	0,009989	—
Assimetria	0,026453	—
Curtose	7,993952	—

Nota: A hipótese nula do teste ADF é a presença de raiz unitária. Para o teste t, a hipótese nula é de média igual a zero. O teste de Jarque–Bera avalia a normalidade dos retornos. O teste Ljung–Box avalia a ausência de autocorrelação até a defasagem indicada, e o teste ARCH avalia a ausência de efeitos ARCH. Os momentos descritivos foram calculados para a série de retornos.

Apêndice B

Resultados complementares dos modelos

B.1 Estimação dos modelos GARCH

Tabela B.1: Resultados da estimação do modelo GARCH(1,1)

Parâmetro	Coeficiente	Erro-padrão	Estatística t	p-valor
ω	0,0113	0,002652	4,275	$< 0,001$
α_1	0,1102	0,01128	9,766	$< 0,001$
β_1	0,8830	0,01143	77,283	$< 0,001$
ν	7,8309	0,790	9,909	$< 0,001$

Fonte: Elaboração própria.

B.2 Estimação dos modelos EGARCH

Tabela B.2: Resultados da estimação do modelo EGARCH(1,1)

Parâmetro	Coeficiente	Erro-padrão	Estatística t	p-valor
ω	-0,001817	0,002462	-0,738	0,461
α_1	0,1894	0,01774	10,673	$< 0,001$
γ_1	0,0571	0,008105	7,042	$< 0,001$
β_1	0,9802	0,003881	252,559	$< 0,001$
ν	8,3171	0,881	9,436	$< 0,001$

Fonte: Elaboração própria.

B.3 Importância das variáveis do Random Forest

Tabela B.3: Importância das variáveis no modelo Random Forest

Variável	Importância
ma_abs_5	0,163
ret_lag1	0,118
vol_lag1	0,105
ma_abs_21	0,089
vol_hist_21	0,088
vol_lag3	0,082
vol_lag2	0,070
ret_lag2	0,066
rsi_14	0,061
ret_lag3	0,052

Fonte: Elaboração própria.

B.4 Resultados completos do teste Diebold-Mariano

Tabela B.4: Resultados completos do teste Diebold–Mariano para MSE

Modelo A	Modelo B	Perda média A	Perda média B	Diferença média	DM-HLN	p-valor
RF	GARCH	$2,6044 \times 10^{-8}$	$2,6638 \times 10^{-8}$	$-5,9409 \times 10^{-10}$	-1,128	0,259
RF	EGARCH	$2,6044 \times 10^{-8}$	$2,6429 \times 10^{-8}$	$-3,8517 \times 10^{-10}$	-0,700	0,484
GARCH	EGARCH	$2,6638 \times 10^{-8}$	$2,6429 \times 10^{-8}$	$2,0892 \times 10^{-10}$	0,932	0,351

Nota: Todas as comparações utilizam 1.602 observações.
Fonte: Elaboração própria.

Tabela B.5: Resultados completos do teste Diebold–Mariano para QLIKE

Modelo A	Modelo B	Perda média A	Perda média B	Diferença média	DM-HLN	p-valor
RF	GARCH	-8,456588	-8,448184	-0,008404	-0,827	0,408
RF	EGARCH	-8,456588	-8,451241	-0,005347	-0,525	0,600
GARCH	EGARCH	-8,448184	-8,451241	0,003057	0,440	0,660

Nota: Todas as comparações utilizam 1.602 observações.
Fonte: Elaboração própria.

B.5 Diagnóstico da estimação do modelo EGARCH na janela rolante

Tabela B.6: Diagnóstico da estimação do modelo EGARCH na janela rolante

Indicador	Valor
Código de convergência	4
ω	-0,003792
α_1	-0,014641
γ_1	0,047024
β_1	0,998163
ν	7,260858
Log-likelihood	-4.226,815056
Variância prevista	250,410050
Variância condicional máxima	6.732,004133

Nota: O código de convergência 4 corresponde à mensagem "Inequality constraints incompatible".
Fonte: Elaboração própria.

Tabela B.7: Diagnóstico de uma estimação adicional do EGARCH na janela rolante

Indicador	Valor
Código de convergência	0
ω	-0,686414
α_1	-70,018303
γ_1	-96,683267
β_1	0,836858
ν	2,050000
Log-likelihood	-7.488,478200
Variância prevista	$4,56 \times 10^{28}$
Variância condicional máxima	5.285.518,608281

Nota: Embora o algoritmo tenha reportado convergência, os valores estimados e a previsão de variância indicam instabilidade numérica.
Fonte: Elaboração própria.

B.6 Importância das variáveis do Random Forest com janela rolante

Tabela B.8: Importância das variáveis no modelo Random Forest

Variável	Importância
ret_lag5	0,109
vol_lag5	0,100
ret_lag1	0,100
vol_lag1	0,093
vol_hist_21	0,092
ma_abs_21	0,089
ma_abs_5	0,078
vol_lag4	0,064
ret_lag4	0,057
ret_lag3	0,050

Fonte: Elaboração própria.

B.7 Resultados completos do teste Diebold-Mariano com janela rolante

Tabela B.9: Resultados completos do teste Diebold-Mariano para MSE — janela rolante

Modelo A	Modelo B	Perda média A	Perda média B	Diferença média	DM-HLN	p-valor
RF	GARCH	$2,6998 \times 10^{-8}$	$2,6144 \times 10^{-8}$	$8,5353 \times 10^{-10}$	2,547	0,011

Nota: A comparação utiliza 1.602 observações.
Fonte: Elaboração própria.

Tabela B.10: Resultados completos do teste Diebold-Mariano para QLIKE — janela rolante

Modelo A	Modelo B	Perda média A	Perda média B	Diferença média	DM-HLN	p-valor
RF	GARCH	-8,434652	-8,458051	0,023399	2,376	0,018

Nota: A comparação utiliza 1.602 observações.
Fonte: Elaboração própria.